

Informe Final — Proyecto Integrador

Minería de Datos 1

Integrantes: [Nombre 1] · [Nombre 2] | Comisión: [X] | Fecha: [Completar]

1. Contexto y objetivo

El presente proyecto analiza un dataset de usuarios de una plataforma de streaming con variables demográficas, de comportamiento y de soporte. El objetivo es aplicar los contenidos de Minería de Datos 1 para construir un análisis con decisiones justificadas, trazabilidad del proceso y comunicación clara de resultados. Las preguntas definidas son: (1) ¿El plan de suscripción influye en el tiempo de visualización mensual? (2) ¿Los usuarios con mayor tiempo de visualización generan menos tickets de soporte? (3) ¿Existen perfiles diferenciados de usuarios según su comportamiento de consumo y soporte? El alcance es exploratorio y no incluye modelado predictivo.

2. Dataset y calidad inicial

El dataset `streaming_users_dirty.json` contiene 8160 registros y 8 columnas: `user_id`, `age`, `subscription_plan`, `monthly_watch_time_mins`, `country`, `favorite_genre`, `last_login_date` y `customer_support_tickets`. Se detectaron los siguientes problemas de calidad: 126 filas duplicadas; nulos en `monthly_watch_time_mins` (193), `favorite_genre` (240) y `last_login_date` (320); inconsistencias en `subscription_plan` (15 variantes para 3 planes), `country` (26 variantes para 7 países) y `favorite_genre` (29 variantes para 7 géneros); valores imposibles en `age` (-5, 130, 150), `monthly_watch_time_mins` (negativos, 50000, 99999) y `customer_support_tickets` (-1, 99, 150); formatos mixtos y fechas futuras en `last_login_date`.

Variable	Problema	Registros afectados
— (filas)	Duplicados completos	126
<code>subscription_plan</code>	15 variantes para 3 planes	Todo el dataset
<code>country</code>	26 variantes para 7 países	Todo el dataset
<code>favorite_genre</code>	29 variantes + nulos	240 nulos
<code>age</code>	Valores imposibles (-5, 130, 150)	74
<code>monthly_watch_time_mins</code>	Negativos, 50000/99999 + nulos	250 + 193 nulos
<code>customer_support_tickets</code>	Negativos y > 50	96
<code>last_login_date</code>	Formatos mixtos + fechas futuras + nulos	882 + 320 nulos

3. Decisiones de limpieza y preparación

Cada decisión se tomó con base en evidencia observada. Se eliminaron los 126 duplicados. Las variables categóricas se normalizaron mediante mapeo explícito de todas las variantes a las categorías correctas. Se eliminaron registros con valores imposibles: `age` fuera del rango 13-100 (n=74); `monthly_watch_time_mins` negativos o superiores a 10000 (n=80); `customer_support_tickets` negativos o superiores a 50 (n=96). Los nulos en `monthly_watch_time_mins` se imputaron con la mediana (759.4 min), justificado por la distribución simétrica. Los nulos en `favorite_genre` se imputaron con la moda al ser variable nominal sin orden. En `last_login_date` se unificaron formatos y se eliminaron 882 registros con fechas futuras imposibles; los nulos restantes se imputaron con la mediana de fechas válidas. El dataset final contiene 6672 registros (retención: 81.8%) sin valores nulos. El registro completo de transformaciones se encuentra en `logs/pipeline_log.csv`.

4. Hallazgos del análisis exploratorio

La distribución de `monthly_watch_time_mins` es aproximadamente simétrica con mediana ~760 minutos. Los tres planes tienen distribución equilibrada en el dataset. Hallazgo principal (P1): el plan de suscripción se asocia positivamente al tiempo de visualización. Los usuarios Premium tienen el mayor consumo promedio, seguidos por

Estandar y Basico, con diferencias consistentes en media y mediana. Hallazgo secundario (P2): la correlacion entre monthly_watch_time_mins y customer_support_tickets es cercana a cero. El volumen de tickets no depende del nivel de consumo. El analisis multivariado mostro que las variables numericas tienen correlaciones bajas entre si, indicando que cada una aporta informacion independiente al perfil del usuario.

5. Escalamiento y PCA

Se aplico PCA sobre age, monthly_watch_time_mins, customer_support_tickets y plan_num (codificacion ordinal: Basico=1, Estandar=2, Premium=3), escaladas con StandardScaler. Se excluyeron user_id, country y favorite_genre. Las cuatro variables aportan varianza de forma distribuida, coherente con las bajas correlaciones del EDA. Las dos primeras componentes explican aproximadamente el 55-65% de la varianza total. PC1 captura la dimension de consumo y plan (perfil de suscripcion); PC2 captura la dimension demografica y de soporte (perfil del usuario). La proyeccion en PC1-PC2 muestra cierta separacion entre planes con superposicion parcial entre grupos.

6. Conclusiones y limitaciones

P1 - El plan de suscripcion se asocia positivamente al tiempo de visualizacion mensual: usuarios Premium tienen mayor consumo y Basico el menor. La relacion es gradual y consistente. P2 - El tiempo de visualizacion no se asocia al volumen de tickets de soporte. Ambas variables son independientes. P3 - Existen perfiles diferenciados parcialmente, con el consumo y el plan como dimensiones principales de separacion. Limitaciones: el dataset no incluye historial de sesiones ni de pagos; la eliminacion de fechas futuras reduce la representatividad; el analisis es exploratorio y no establece causalidad.

Repositorio: [https://github.com/\[usuario\]/PI_Mineria_Datos_1](https://github.com/[usuario]/PI_Mineria_Datos_1) | Streamlit: [https://\[app\].streamlit.app](https://[app].streamlit.app)